Praca domowa 2

Temat Kuzushiji-MNIST

Grzegorz Grygorowicz

崩し字(kuzushiji) - z japońskiego zawalone znaki, są to znaki zapisywane kursywą przed reformą w okresem Meiji, po której umiejętność czytania tych znaków zaczeła przepadać z czasem. Obecnie umieją je czytać tylko eksperci.

```
In []: import numpy as np
   import pandas as pd
   import os
   import matplotlib.pyplot as plt
   from tensorflow import keras
   from tensorflow.keras.models import Sequential
   from tensorflow.keras.layers import Dense, Flatten, Conv2D, Dropout, MaxPooling2
   from tensorflow.keras.utils import to_categorical
   from sklearn.model_selection import train_test_split
   from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay
   import scipy as sp
   import random
In []: BATCH_SIZE = 64
SEED = 278839
```

Dane

Pierwszą bazą danych jest 70000 obrazków o wymiarze 28x28, w odcieni szarości. Jest 10 klas znaków hiragany: お、き、す、つ、な、は、ま、や、れ、を.

Drugą bazą danych jest augumentacja tych obrazów, najpiew obrócenie je randomowo i przejście przez funckje magnitudy gradientu, przez co nie są zamalowane całe znaki a jedynie kontur.

```
In [ ]: train_set = np.load("kmnist-train-imgs.npz")["arr_0"]
    train_labels = np.load("kmnist-train-labels.npz")["arr_0"]

test_set = np.load("kmnist-test-imgs.npz")["arr_0"]
    test_labels = np.load("kmnist-test-labels.npz")["arr_0"]

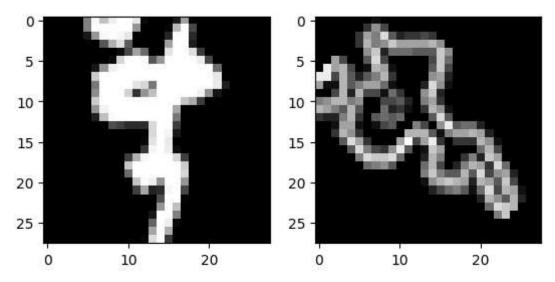
length = len(np.unique(train_labels))

train_labels = to_categorical(train_labels, length)
    test_labels = to_categorical(test_labels, length)
```

```
img1 = train_set[15]
img2 = sp.ndimage.rotate(img1, angle=45, reshape=False)
z = sp.ndimage.gaussian_gradient_magnitude(img2, 0.3)
plt.subplot(1, 2, 1)
plt.imshow(img1, cmap="gray")
```

```
plt.subplot(1, 2, 2)
plt.imshow(z, cmap="gray")
```

Out[]: <matplotlib.image.AxesImage at 0x1b280937d00>



```
In [ ]: augmentedTrainData = []
        augmentedTestData = []
        random.seed(SEED)
        for image in test_set:
            rotatedImage = sp.ndimage.rotate(image, angle=random.randint(0, 360), reshar
            augmentedImage = sp.ndimage.gaussian_gradient_magnitude(rotatedImage, 0.3)
            augmentedTestData.append(augmentedImage)
        for image in train_set:
            rotatedImage = sp.ndimage.rotate(image, angle=random.randint(0, 360), reshar
            augmentedImage = sp.ndimage.gaussian_gradient_magnitude(rotatedImage, 0.3)
            augmentedTrainData.append(augmentedImage)
        aTestData = np.array(augmentedTestData)
        # a1Test = {"arr_0": aTestData}
        # np.savez('a3/a3Test.npz', **a1Test)
        aTrainData = np.array(augmentedTrainData)
        # a1Train = {"arr_0": aTrainData}
        # np.savez('a3/a3Train.npz', **a1Train)
```

Konwolucyjna sięc neuronowa

2 warstwy konwolucji. W pierwszej 32 węzły, w drugiej 64 z filterami 5x5, z funckją aktywacji relu. Wielkość inputu 28x28x1 i paddingiem takim samym. Normalizacja 40% dropout

```
In []: model = Sequential()
    model.add(Conv2D(32, (5, 5), activation='relu', input_shape=(28, 28, 1), padding
    model.add(MaxPooling2D(2, 2))
    model.add(BatchNormalization())
    model.add(Conv2D(64, (5, 5), activation='relu'))
    model.add(Flatten())
    model.add(Dense(64, activation='relu'))
    model.add(Dropout(0.4))
    model.add(Dense(length, activation="softmax", kernel_regularizer='12'))
```

```
model.summary()
model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accur
```

Model: "sequential_1"

Layer (type)	Output Shape	Param #
conv2d_2 (Conv2D)	(None, 28, 28, 32)	832
<pre>max_pooling2d_1 (MaxPooling 2D)</pre>	(None, 14, 14, 32)	0
<pre>batch_normalization_1 (Batc hNormalization)</pre>	(None, 14, 14, 32)	128

Output Shape	Param #
(None, 28, 28, 32)	832
(None, 14, 14, 32)	0
(None, 14, 14, 32)	128
(None, 10, 10, 64)	51264
(None, 6400)	0
(None, 64)	409664
(None, 64)	0
(None, 10)	650
	(None, 28, 28, 32) (None, 14, 14, 32) (None, 14, 14, 32) (None, 10, 10, 64) (None, 6400) (None, 64) (None, 64)

Total params: 462,538 Trainable params: 462,474 Non-trainable params: 64

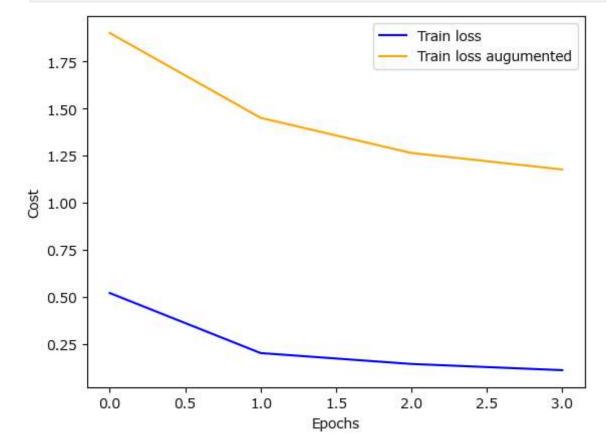
Trenowanie na danych oryginalnych

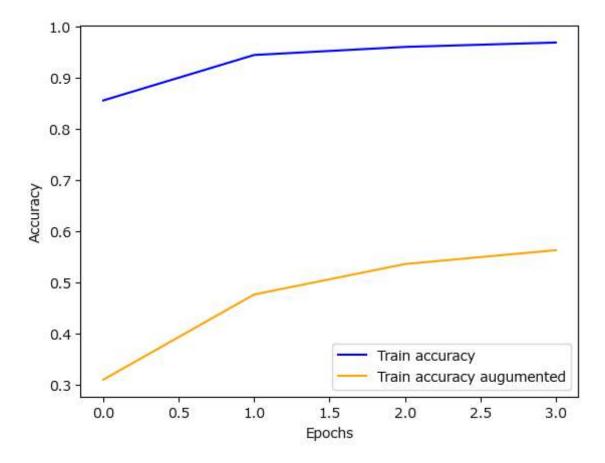
Trenowanie na danych zaugumentowanych

Wyświetlenie dla oby dwóch wersji baz danych wykresów starty i dokładności.

```
In []: plt.plot(history.history['loss'], label='Train loss', color='blue')
   plt.plot(history2.history['loss'], label='Train loss augumented', color='orange'
   plt.legend()
   plt.xlabel('Epochs')
   plt.ylabel('Cost')
   plt.show()

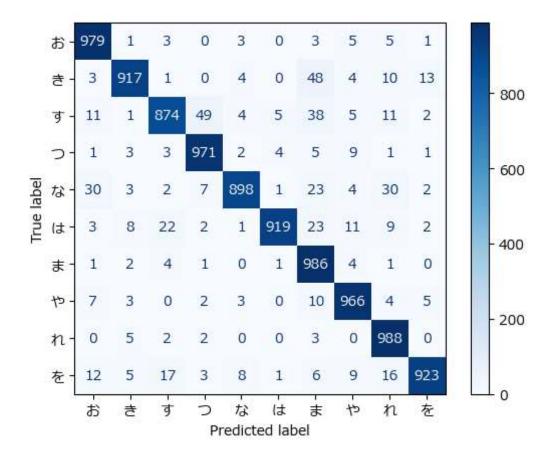
plt.plot(history.history['accuracy'], label='Train accuracy', color='blue')
   plt.plot(history2.history['accuracy'], label='Train accuracy augumented', color=
   plt.legend()
   plt.xlabel('Epochs')
   plt.ylabel('Accuracy')
   plt.show()
```



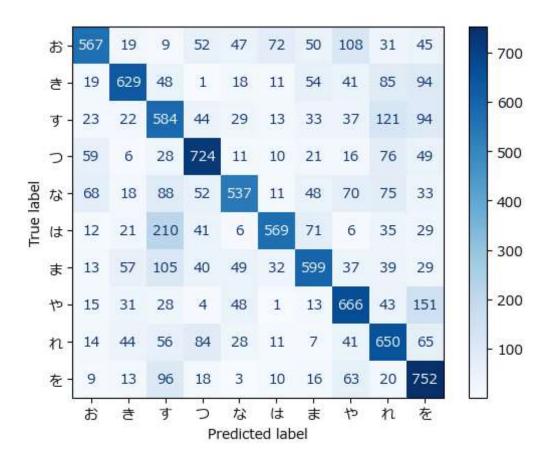


Wyświetelnie dla oryginalnych danych testowych straty i dokładności oraz macierzy błędu.

```
In [ ]: print("Evaluate model on test data")
       results = model.evaluate(test_set, test_labels, batch_size=BATCH_SIZE)
       print("test loss, test accuracy:", results)
       print("Prediction")
       prediction = model.predict(test_set)
       conMatrix = confusion_matrix(test_labels.argmax(axis=1), prediction.argmax(axis=
       disp = ConfusionMatrixDisplay(confusion_matrix=conMatrix, display_labels="おきす
       plt.rcParams['font.family'] = 'Meiryo'
       disp.plot(cmap=plt.cm.Blues)
       plt.show()
      Evaluate model on test data
      y: 0.9421
     test loss, test accuracy: [0.28784579038619995, 0.9420999884605408]
     Prediction
      313/313 [============= ] - 2s 5ms/step
```



Wyświetelnie dla zaugumentowanych danych testowych straty i dokładności oraz macierzy błędu.



K-Najbliższych Sąsiadów

k = 3

Przygotowanie danych by działały dla KNeighborsClassifier i MLPClassifier

```
In []: nsamples, nx, ny = train_set.shape
    train_set_k = train_set.reshape((nsamples,nx*ny))

    nsamples, nx, ny = test_set.shape
    test_set_k = test_set.reshape((nsamples,nx*ny))

    nsamples, nx, ny = aTrainData.shape
    aTrain_set_k = aTrainData.reshape((nsamples,nx*ny))

    nsamples, nx, ny = aTestData.shape
    aTest_set_k = aTestData.reshape((nsamples,nx*ny))
```

Dla oryginalnych danych

Wyświetlenie dokładności i macierzy błędu.

```
In [ ]: from sklearn.neighbors import KNeighborsClassifier
knn = KNeighborsClassifier(n_neighbors=3)
knn = knn.fit(train_set_k, train_labels)

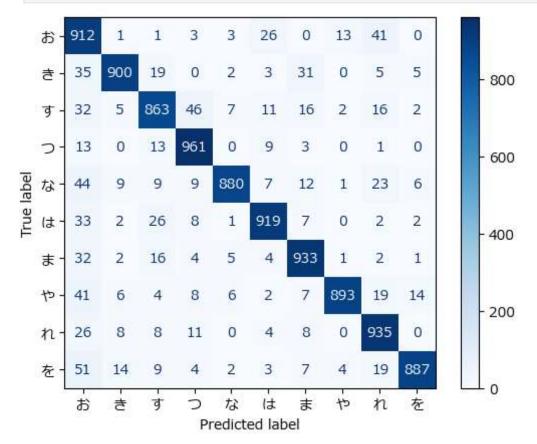
print(knn.score(test_set_k, test_labels)*100)

y_true = test_labels
y_pred = knn.predict(test_set_k)
```

```
conMatrix = confusion_matrix(y_true.argmax(axis=1), y_pred.argmax(axis=1))
```

90.73

```
In []: disp = ConfusionMatrixDisplay(confusion_matrix=conMatrix, display_labels="おきす
plt.rcParams['font.family'] = 'Meiryo'
disp.plot(cmap=plt.cm.Blues)
plt.show()
```



Dla danych zaugumentowanych

```
In [ ]: knn = KNeighborsClassifier(n_neighbors=3)
knn = knn.fit(aTrain_set_k, train_labels)

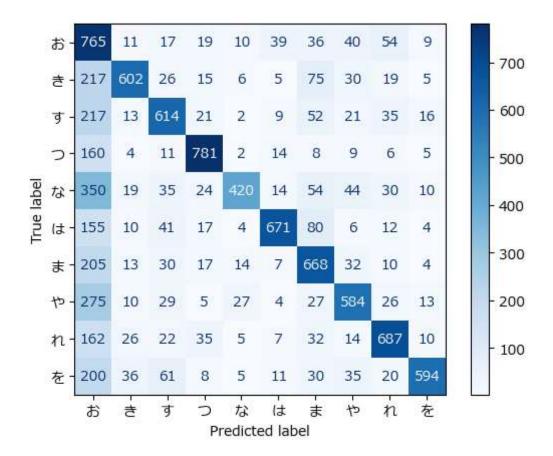
print(knn.score(aTest_set_k, test_labels)*100)

y_true = test_labels
y_pred = knn.predict(aTest_set_k)

conMatrix = confusion_matrix(y_true.argmax(axis=1), y_pred.argmax(axis=1))
```

61.29

```
In [ ]: disp = ConfusionMatrixDisplay(confusion_matrix=conMatrix, display_labels="おきす"
    plt.rcParams['font.family'] = 'Meiryo'
    disp.plot(cmap=plt.cm.Blues)
    plt.show()
```



Sieć neuronowa

Dla oryginalnych danych

```
In []: from sklearn.neural_network import MLPClassifier

nn = MLPClassifier(solver='adam', hidden_layer_sizes=(50, 50, 50), random_state=
nn.fit(train_set_k, train_labels)

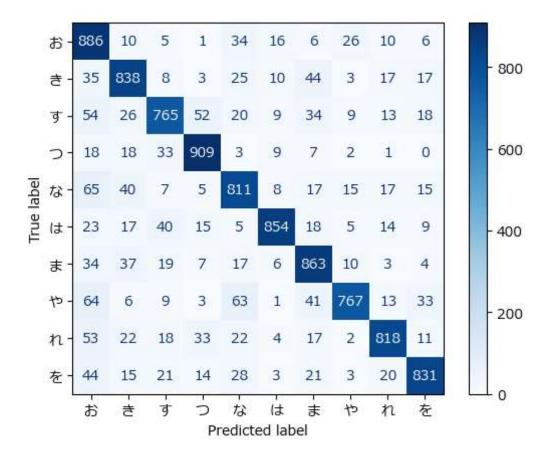
print(nn.score(test_set_k, test_labels) * 100)

y_true = test_labels
y_pred = nn.predict(test_set_k)

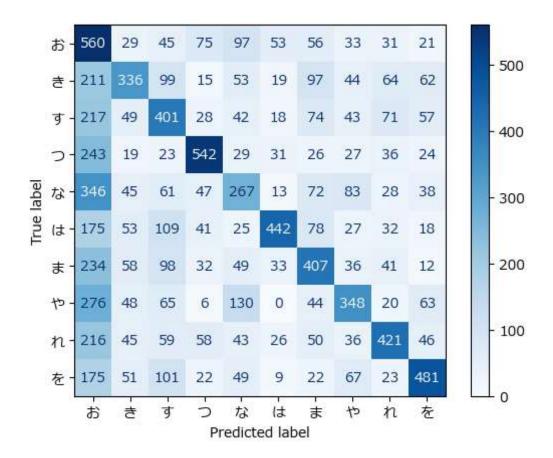
conMatrix = confusion_matrix(y_true.argmax(axis=1), y_pred.argmax(axis=1))

82.72

In []: disp = ConfusionMatrixDisplay(confusion_matrix=conMatrix, display_labels="おきす plt.rcParams['font.family'] = 'Meiryo'
disp.plot(cmap=plt.cm.Blues)
plt.show()
```



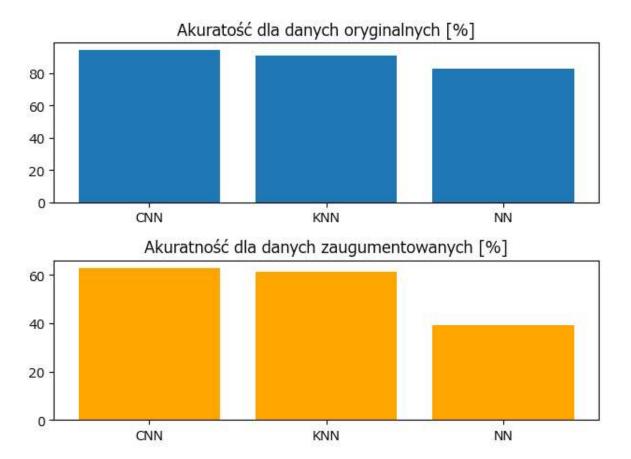
Dla zaugumentowanych danych



Podsumowanie

```
In []: types = ["CNN", "KNN", "NN"]
    acc = [94.20999884605408, 90.73, 82.72]
    acc_a = [62.76999711990356, 61.29, 38.98]

fig, ax = plt.subplots(2)
    ax[0].bar(types, acc)
    ax[0].set_title("Akuratość dla danych oryginalnych [%]")
    ax[1].bar(types, acc_a, color='orange')
    ax[1].set_title("Akuratność dla danych zaugumentowanych [%]")
    plt.tight_layout()
    plt.show()
```



Jak można zauważyć na wykresie, najdokładniejszym klasyfikatorem jest konwolucyjna sieć neuronowa ok 94% dla oryginalnych danych i ok 63% dla zaugumentowanych danych. Potem jest klasyfikator K-najbliższych sąsiadów ok 91% dla oryginalnych danych i ok 61% dla zaugumentowanych danych. Najgorzej wypadła sieć neuronowa z wynikiem ok 83% dla oryginalnych danych i ok 39% dla zaugumentowanych danych.

Bibliografia

- https://www.kaggle.com/datasets/anokas/kuzushiji
- https://www.upgrad.com/blog/basic-cnn-architecture/
- Wykłady i laboratoria